


A COMPARISON / DECISION MODELS

Cloudflare

Clef 与 Jev

模型、供应路径与判断成本。
从接得上，到值得放进工作流。



从这里翻开

先确定正在比较的是模型还是入口，再读价格、限制和试验方法。

01	先把模型、接口与平台分开	3
02	现在有哪些供应路径	4
03	便宜多少，以及真正该算什么	5
04	“API 兼容”仍然需要适配层	6
05	厂商的比较，告诉了我们什么	7
06	第一轮试验应该怎样长出来	7
07	这篇专题怎样继续维护	8
S	来源索引与署名	9

来源编号可点击。开放状态与生效日期按资料截止日记录；实施代码与详细状态约束另放仓库的技术参考。

一个便宜的判断接口，值得拿来替代哪些大模型调用？这个问题不能只比较单价。还要知道返回的数字代表什么、模型读到了多少材料，以及一次误判会把后续工作带到哪里。

本篇核对截至 2026-10-02 的官方模型卡、接口和供应目录。下面的价格是标价，费用示例是演算，性能数据有明确出处；本资料包没有调用真实模型。不要把离线请求测试读成模型效果测试。

01

MODELS

先把模型、接口与平台分开

Jev 是 TypeSafe 的决策模型；Clef 与 Clef-flash 是 Cloudflare 的决策模型。Cloudflare 同时提供自有模型和第三方 Jev 的调用入口。因此，选择 CF 不等于只能用 Clef，比较 Jev 与 Clef 也不必同时搬迁账户和整套应用。S17 S18 S73

它们接收待判断的状态与带类型的问题，不以长篇回答为目标。noul 返回条件成立的概率；choice 在有限选项中选择并返回各选项概率；score 在有序等级上给出分数及分布。适合判断、分类和排序，不能直接替代负责开放式规划与写作的模型。S76

对象	解决的问题	不能从名字推出的事
模型	用什么权重做判断	在哪个地区、哪个平台实际运行
API / SDK	请求、响应和错误怎样表达	换一个模型 ID 就能无条件互换
接入与结算平台	使用哪种凭据、账单、日志和路由	后面一定是独立的推理供应商

一个常见的比较误差，是将“Jev 走 OpenRouter、Clef 走 CF”的总延迟写成模型速度差。这里同时变了模型和网络路径。更清楚的实验是先固定 CF，比较三款模型；再固定 Jev，比较原厂与不同网关。

02

PROVIDERS

现在有哪些供应路径

接入路径	模型选择器	输入价：美元／百万 token
CF Workers AI → Clef	@cf/cloudflare/clef	0.24
CF Workers AI → Clef-flash	@cf/cloudflare/clef-flash	0.09
CF 第三方目录 → Jev	typesafe/jev	0.042
TypeSafe 原厂 → Jev	jev-1.13.0	0.042
OpenRouter → Jev	typesafe/jev-1.13	0.042
Vercel AI Gateway → Jev	typesafe-ai/jev	页面显示 0.04；精度另核

CF 两款 Clef 的价格来自 Workers AI；Jev 的 CF、原厂和 OpenRouter 路径都明列输入 \$0.042、输出 \$0。Vercel 官方目录显示的是 \$0.04，现有显示精度不足以判断它是否真的比 \$0.042 更便宜。本次只取到了该官方页面的搜索摘录，不用它推算精确账单。[S17](#) [S18](#) [S73](#) [S74](#) [S75](#) [S81](#)

TypeSafe 原厂使用 /v1/systemone。OpenRouter 既有 /api/alpha/decisions，也有适配 TypeSafe SDK 的 /api/v1/systemone，使用 OpenRouter 的 key 与账单。CF 则提供 AI binding 和 /accounts/{account}/ai/run 统一 REST 入口，不能自行猜一个 CF /decisions 路由。[S74](#) [S76](#) [S79](#)

OpenRouter 的 Jev 供应商仍列为 TypeSafe，CF 目录也标明 Jev 为第三方。多接几个网关可以改变入口和结算方式，但不能据此声称已经获得几套相互独立的模型后端。[S73](#) [S75](#)

开放权重是另一条路线

Clef 与 Clef-flash 发布了 Apache-2.0 权重，可以研究和自托管；硬件、推理服务与维护成本由部署者承担。Jev 在这里列出的则是托管 API。把 Clef 自托管跑起来，是另一项实验，不应套用 CF 的按 token 标价。配套 CF 强化学习服务目前采用设计合作路线，不能当作 \$5 Workers Paid 包含的自助训练功能。[S82](#) [S83](#) [S16](#)

03

COST

便宜多少，以及真正该算什么

假设一个月完成 10,000 次判断，每次的**总计费输入**为 5,000 token，包含状态、问题与选项，总计 5,000 万输入 token；不发生缓存和重试。按模型标价演算： [S17](#) [S18](#) [S73](#)

模型	计算	模型费用
Jev	$50 \times \$0.042$	\$2.10
Clef-flash	$50 \times \$0.09$	\$4.50
Clef	$50 \times \$0.24$	\$12.00

这是假定各路线都计入同样数量 token 的对照，不是“同一句话天然使用相同 tokenizer”的保证。实际应读回每条路线的 usage；多题可以共用状态时，也不能把每道题都粗暴算成一次完整长请求。

CF Unified Billing 对充值另收 5%，例如购买 \$100 credits 支付 \$105；推理标价本身不加价。Workers AI 可以采用不同计费设置，不能给全部调用无条件乘上 1.05；走第三方 Jev 时尤其要明确使用的是哪条授权与结算路线。 [S80](#)

个人用量下，每月几美元的模型价差可能小于一次错误路由造成的返工。更合适的成本表是：**模型 + 重试 + 大模型接管 + Worker / 日志 + 人工核对**。一个更便宜但经常把“没读够材料”判成“可以开始”的模型，未必更省。

04

CONTRACTS

“API 兼容” 仍然需要适配层

相同的问题，可以有不同的请求外壳

CF 的 Jev 模型卡使用 `env.AI.run('typesafe/jev', { state, questions })`；Clef 模型卡除了外层选择器，还要求输入中的 `model: 'clef' 或 'clef-flash'`。统一 REST 入口另包一层 `{ model, input }`。本包离线示例把这些外壳分别构造，不把它们混成一个字符串替换。[S73](#) [S17](#) [S18](#) [S79](#)

Vercel 的示例使用 `experimental_evaluate`，其中布尔问题写作 `boolean`；这是 SDK 的表述，不能原样当成原厂 `noul` 请求。平台协议、SDK 版本、请求字段与返回字段都应在一次适配测试中保留。[S81](#)

上下文限制要按路由记录

Clef 两款目录列 65,536 token。Jev 原厂是**整个请求 64k、状态加最长单题 32k**，因为同一状态用于多个问题；CF 与 OpenRouter 目录则直接列 32,000。比较时以各自实际入口的限制为准，不写成泛化的“Jev 永远只有 32k”。[S17](#) [S18](#) [S74](#) [S75](#)

Clef 当前 schema 允许最多 64 个问题，并提供最多四张嵌入式图片的扩展，不接受远程图片 URL；长状态可能被截断。模型宣传中的视觉能力不等于任意视频文件都能塞进当前请求。Jev 是纯文本输入，图片需要预先转换成文字，转换误差也应计入结果。[S17](#) [S18](#) [S74](#)

同名置信度，不能共享一个阈值

Jev 的 `confidence` 是从输出概率分布算出的统计量，不是另一个监督者确认的正确率。原厂也列出了否定、数值／日期、上下文干扰等已知边界：同义的 `Noul` 与 `Choice` 表述不一定给出一致结果，两个互补问题也未必严格相加为一。[S77](#) [S78](#)

因此，把旧模型的 0.9 阈值照搬给新模型，没有自动成立的理由。拒绝回答、交给更强模型、继续读取材料等出口应当在应用里明确存在。权限、精确计数和日期比较可以由程序确定的部分，不交给概率判断充当最终裁决。

05

EVIDENCE

厂商的比较，告诉了我们什么

Cloudflare 发布文中的自测并没有形成处处相同的排序。下面选取三项，展示排名会随任务改变；这些不是本资料包的实测，也不是独立复现。S16

指标	Clef	Clef-flash	Jev
When2Call · accuracy	72.37	65.58	80.97
CLINC150+OOS · macro-F1	97.43	66.77	89.27
BRIGHT · nDCG@10	45.91	39.26	47.52

不能把不同比例尺的三项平均成自己的总分。更值得追问的是：面对“不属于任何现有类别”的输入，是否会硬选一个？检索相关性强，不代表工具调用时机也强；更大的模型，也不意味着每个任务一定优于小款。

速度同样应该回到实际入口测。关闭响应缓存，保留重试和失败，报告相同输入组的 p50、p95 与完成率，而不是只挑一条最快响应。供应商自测、网关实时统计和个人网络下的时延属于三种观察，不能拼成同一张排行榜。

06

EXPERIMENT

第一轮试验应该怎样长出来

建议先做一个窄任务：收到材料以后，下一步是**直接分类、读取原文、检索上下文，还是材料不足**。这是可重做的建议性决策，不直接产生外部写入。先写简单规则作基线，再比较模型是否真的改善了规则做不好的部分。

样本先拆成开发集与留出集。中文、英文、中英混合分别保留；加入否定、修订、引述、相近选项、找不到答案与刻意缺少背景的材料。TypeSafe 明确说 Jev 的训练主要面向英语，CJK 可以处理但不保证同等表现，因而中文材料值得单独检验。S74

分两轮改变条件：第一轮在 CF 上比较 Jev、Clef-flash、Clef，固定任务与外壳适配后的语义输入；第二轮固定 Jev、相同语义版本与输入，再比较 TypeSafe／CF／OpenRouter。若某个入口不能钉住同一版本，就把它作为不同实验条件，而不是假装只换了网络。

最有用的指标通常不是一个总准确率，而是：在愿意接受的误判风险下，自动处理了多少；错误地认为材料足够的比例；交给人或大模型的比例；完成率、尾部延迟和每百次被接受判断的总成本。少量样本只能帮助发现问题，不能宣称已校准到千分之一风险。

另外做几项便宜的对照：交换选项顺序、替换同义词、加入无关段落、把一题单独发送或与其他问题合并。保持语义相同时结果变化多大，本身就是值得记录的性质。数据、prompt、选项集合和实际响应版本应一起保存，才能复读失败。

本包 `examples/decision-routing/` 只提供离线请求构造与成本演算。它没有配置账号、发送请求或生成看似真实的模型结果；首轮语义测评仍待执行。

07

MAINTENANCE

这篇专题怎样继续维护

服务页保留当前可用入口；用例页解释为何需要这个判断；示例固定请求形状和检查方法；专题记录比较；本期报告则保存当时知道的情况。新的价格或模型版本先更新来源和路由记录，再定位受影响的读物，不要求每次重写整份手册。

这里的最小比较单位建议是：**任务版本 × 输入集合 × 模型版本 × 供应路径 × 策略阈值**。缺掉任何一项，“上次好用，这次变差”都会难以解释。可以从一张简单的运行记录开始，不必先做在线 benchmark 平台。

来源索引

本次重新核对决策模型、接入路径与价格；其他发布条目沿用 2026-10-02 原版来源记录。资料核验不等于账户或模型实测。

S16	Clef 与强化学习平台发布	S77	TypeSafe: confidence 的含义
S17	Clef 模型卡	S78	TypeSafe: Jev 1.13 已知能力边界
S18	Clef-flash 模型卡	S79	Cloudflare AI Gateway: 统一 REST API
S73	Jev: Cloudflare 第三方模型目录	S80	Cloudflare AI Gateway: Unified Billing
S74	TypeSafe: Jev 版本、价格与上下文预算	S81	Vercel AI Gateway: Jev 目录显示价与 SDK 示例
S75	OpenRouter: Jev 1.13 价格与供应商	S82	Cloudflare Clef: 开放模型权重与模型卡
S76	OpenRouter: Jev 的两种接口	S83	Cloudflare Clef-flash: 开放模型权重与模型卡

关于这一版

面向个人使用的独立参考资料，不是 Cloudflare 官方出版物。产品事实保留来源，场景与判断属于编辑分析。
本次未进行账户操作或云端部署。

GitHub · github.com/IndelibleVivi

made by Faye & Cove